Contents

1 Qu'est-ce qu'un LLM? 1
1.1 Principe de base 1
1.2 Comment il apprend ? 1
1.3 Ce que ça donne 2
1.4 Qu'est-ce que le function calling ? 2

1 Qu'est-ce qu'un LLM?

Un LLM (Large Language Model, ou "grand modèle de langage" en français) est un type d'intelligence artificielle entraîné sur d'énormes quantités de texte pour comprendre et générer du langage humain.

1.1 Principe de base

Concrètement, un LLM est un réseau de neurones (le plus souvent basé sur une architecture appelée Transformer) qui a appris, à partir de milliards de phrases, à prédire le token suivant dans une séquence de texte.

Par exemple, si on lui donne "Le ciel est…", le modèle a appris à partir de ses données d'entraînement que "bleu" est une continuation statistiquement probable.

1.2 Comment il apprend ?

1. Entraînement (pre-training) : le modèle lit des quantités massives de texte (livres, sites web, code, etc.) et apprend les régularités statistiques du langage — grammaire, faits, styles, raisonnements implicites.
2. Fine-tuning / alignement : ensuite, on l'ajuste pour qu'il soit utile et sûr — par exemple pour qu'il réponde à des questions plutôt que de simplement continuer un texte, ou qu'il suive des instructions.

1.3 Ce que ça donne

En répétant cette prédiction token par token, le modèle peut :

- Répondre à des questions
- Résumer des textes
- Traduire
- Écrire du code
- Raisonner sur des problèmes (avec des limites)

1.4 Qu'est-ce que le function calling ?

Dans le contexte du projet "call me maybe" : un LLM classique produit du texte libre, pas nécessairement structuré. C'est justement pour ça que le function calling est nécessaire — pour transformer cette capacité de génération de texte en sorties exploitables par des machines (JSON, appels de fonctions typées, etc.).